Verdadero pero invisible: concordancia entre modelos de lenguaje y alcance correctivo de Grok como fact-checker en X

Diego Gamarra, Antoni Homet, Pablo Gálvez, Chonghe Huang
UPF Barcelona School of Management

Resumen

Este estudio caracteriza el comportamiento del asistente Grok como herramienta de verificación de hechos en la red social X. A partir de un corpus propio de 2.353 interacciones reales en inglés y español, recogidas en dos periodos (2025 y 2026), reconstruimos el hilo de tres tweets que compone cada solicitud de verificación (afirmación cuestionada, petición del usuario y respuesta de Grok) y comparamos cada veredicto de Grok con el de un segundo modelo independiente (Gemini), empleando un tercer modelo como evaluador de la concordancia. Los resultados muestran que ambos modelos coinciden en torno al 82% de los casos y que su desacuerdo, una vez controladas las demás variables, se concentra exclusivamente en contenido bélico y político. Los efectos del idioma y del periodo son significativos pero pequeños e independientes entre sí. El hallazgo de mayor relevancia es el alcance: el fact-check típico de Grok alcanza apenas el 0,3% de la audiencia del tweet que corrige. Concluimos que la limitación principal de estas herramientas no es la calidad de su juicio, sino su difusión.

Palabras clave: *Fact-checking, Desinformación, Modelos de lenguaje, Grok, X/Twitter, Alcance correctivo, Análisis de datos.*

Introducción

La integración de modelos de lenguaje de gran escala (LLM) en las redes sociales ha transformado la verificación de información. En X, los usuarios invocan al asistente Grok respondiendo a una publicación, típicamente con la fórmula «@grok is this true?», para recibir un veredicto sobre su veracidad en cuestión de minutos. Este fenómeno se ha desplegado a gran escala, con más de 1,67 millones de solicitudes solo entre febrero y septiembre de 2025 (Renault, Mosleh y Rand, 2026), antes de ser sometido a una evaluación sistemática.

La literatura sobre fact-checking automatizado ha avanzado principalmente en dos direcciones: la exactitud de los veredictos en benchmarks controlados (Guo et al., 2022) y el acuerdo entre evaluadores humanos y modelos (Zheng et al., 2023). Sin embargo, ambas perspectivas comparten una limitación: miden la calidad del juicio sin considerar si ese juicio llega efectivamente a la audiencia que necesita corregirse. Esta disociación entre exactitud y alcance es especialmente relevante en plataformas como X, donde la desinformación se difunde más rápido y más ampliamente que la información veraz (Vosoughi, Roy y Aral, 2018), y donde la corrección llega estructuralmente tarde respecto al pico viral.

Este trabajo analiza cómo se comporta Grok en esa función a partir de datos reales de la plataforma, examinando simultáneamente la consistencia de sus veredictos y su alcance efectivo. La hipótesis de partida es que dos modelos de lenguaje independientes tenderán a converger en sus veredictos, pero que esa consistencia no garantiza por sí sola un impacto efectivo sobre la difusión de la desinformación. Para contrastarla, examinamos dos dimensiones complementarias articuladas en tres preguntas de investigación: el grado de concordancia entre los veredictos de Grok y los de un segundo modelo, los factores que explican su desacuerdo, y el alcance efectivo de la corrección medido en términos de audiencia capturada.

Antecedentes

La verificación profesional ofrece alta fiabilidad pero no escala al volumen de las redes sociales; la verificación automatizada y la distribuida (Community Notes) aportan velocidad, pero se degradan ante contenido reciente y llegan tarde respecto al pico de difusión viral (Guo et al., 2022; Chuai et al., 2024). Grok ocupa una posición singular: su acceso en tiempo real al flujo de X le permite recuperar evidencia posterior a su fecha de corte, pero esa misma fuente carece de proceso editorial y es el principal vector de la desinformación que se le pide verificar. Esta arquitectura es funcionalmente equivalente a los sistemas de Retrieval-Augmented Generation (Lewis et al., 2020), aunque aplicada a una fuente no curada ni verificada.

El antecedente más directo es el de Renault et al. (2026), que documenta una elevada convergencia entre Grok y Perplexity (coincidencia del 52,6%; desacuerdo frontal en solo el 13,6%; correlación de hasta r = 0,69 vía API) y un alcance reducido de las respuestas. Nuestro trabajo replica el hallazgo de convergencia con un segundo modelo distinto (Gemini) y añade tres dimensiones que ese estudio no aborda: un eje bilingüe, un eje temporal y un análisis explícito del alcance correctivo.

La elección de Gemini como modelo de referencia responde a criterios tanto metodológicos como empíricos. Boissonneault y Hensen (2024) evaluaron ChatGPT y Gemini sobre el benchmark LIAR, encontrando que Gemini supera a ChatGPT en exactitud, F1 y AUC-ROC en tareas de detección de fake news. Esta evidencia externa se complementa con nuestra propia validación interna sobre el mismo benchmark, descrita en la sección de métodos.

Objetivos

El objetivo principal es caracterizar de forma sistemática el comportamiento de Grok como fact-checker en X. Los objetivos específicos son:

1. Construir un corpus de interacciones reales en las que los usuarios solicitan verificación a Grok y recopilar sus respuestas.
2. Comparar cada veredicto de Grok con el de un segundo modelo independiente y analizar el grado y los factores de la concordancia.
3. Cuantificar el alcance de la corrección de Grok en relación con el contenido que verifica.

Materiales y métodos

Recogida de datos

Los datos se recogieron de X mediante un scraper comercial de la plataforma Apify, cubriendo dos periodos (1 de marzo–1 de junio de 2025 y 1 de febrero–1 de mayo de 2026) y dos idiomas (inglés y español). Cada interacción se compone de tres tweets encadenados que se reconstruyen en orden inverso al de la conversación real. La extracción parte de las respuestas de Grok, el punto de control de calidad del estudio, filtrando publicaciones del usuario @grok que contienen vocabulario propio de la verificación (Tabla 1). A partir del campo de metadatos inReplyToId se recupera, en una segunda pasada, el tweet que invoca al asistente, y en una tercera, la afirmación cuestionada; los tres conjuntos se unen mediante un left join sobre el identificador del tweet (Figura 1). De cada publicación se conservaron el texto, las seis métricas de engagement, el idioma, la fecha y los identificadores de relación y de autor (Tabla 2).

Figura 1: Pipeline de reconstrucción del hilo de tres tweets

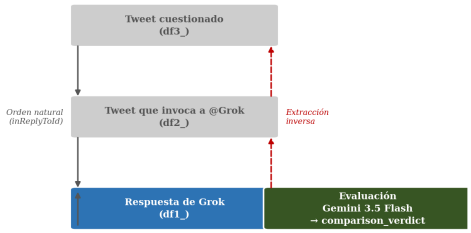


Figura 1: Pipeline de reconstrucción del hilo de tres tweets.

Inglés (selección)	Español (selección)
"true", "false", "accurate", "verified", "unverified", "according to", "fact check", "claim is", "sources"	"verdadero", "falso", "no es cierto", "correcto", "incorrecto", "verificado", "según la información disponible", "reportado por", "pruebas"

Tabla 1: Muestra de los términos de búsqueda por idioma.

Variable	Descripción
id	Identificador único del tweet
text	Texto de la publicación
viewCount	Número de visualizaciones
lang	Idioma de publicación
createdAt	Fecha de publicación
inReplyToId	ID del tweet al que responde
author_followers	Seguidores del autor
author_isAutomated	Cuenta automatizada (bot)

Tabla 2: Principales variables retenidas del scraper.

Procesamiento de datos

El corpus bruto se sometió a un embudo de limpieza sucesivo (Tabla 3). Tras concatenar las tres descargas, se eliminaron los casos en que Grok verificaba una respuesta previa de Grok, los tweets excesivamente largos tratados como outliers, las interacciones sin texto coherente (enlaces o referencias a multimedia), los duplicados generados por la independencia de las búsquedas y, mediante un filtro automático con Gemini, las interacciones que no constituían objeto de fact-checking. La muestra de análisis final fue de 2.353 interacciones, desequilibrada hacia el inglés (2.016) frente al español (337) y hacia 2026 (1.303) frente a 2025 (1.050), con la política como temática dominante (625 casos).

Operación	n
Respuestas de Grok	8.055
Tweet que invoca a Grok	6.379
Tweet cuestionado	5.113
Tres descargas unidas	6.835
Grok vs. Grok	−1.445
Tweets muy largos	−691
Incoherencias y enlaces	−775
Duplicados	−535
No validables	−892
No evaluables + idioma minoritario	−140
Muestra analizada	2.353

Tabla 3: Evolución del corpus durante la limpieza.

Comparación y evaluación

Para cada interacción se generó un veredicto de referencia con un segundo modelo (Gemini 3.1 Flash Lite), alimentado con el mismo contexto del que dispuso Grok y con búsqueda en Google activada. Este modelo se eligió por su equilibrio entre coste y capacidad (Tabla 4) y su poder de verificación se validó previamente sobre el dataset LIAR (Wang, 2017): en una clasificación de seis clases, condición zero-shot y solo texto (n = 1.245 predicciones válidas), alcanzó una accuracy del 30,2%, superando todos los baselines del trabajo original: CNN text-only (27,0%), SVM (25,5%), Bi-LSTM (23,3%) y baseline mayoritario (20,8%). Esta validación, junto con la evidencia previa de Boissonneault y Hensen (2024), fundamenta la idoneidad de Gemini como evaluador externo independiente.

La comparación entre el veredicto de Grok y el de referencia se asignó a un modelo distinto (Gemini 3.5 Flash) por dos motivos: evitar el sesgo de auto-evaluación, ya que un modelo tiende a favorecer sus propios patrones de respuesta, y disponer de mayor capacidad de razonamiento para contrastar dos textos. El prompt evaluador se redactó en inglés para introducir ruido distanciatorio respecto a la evaluación del paso anterior (cuyo prompt es en castellano). El evaluador devolvió tres variables: comparison_verdict (ordinal: same, mostly_same, slight_diff, disparity), la confianza del veredicto (0–1) y la categoría temática entre catorce posibles.

Modelo	Input*	Output*
Gemini 3.1 Flash Lite	0,25	1,50
Gemini 3.5 Flash	1,50	9,00
Claude Haiku 4.5	1,00	5,00
GPT-4o-mini	0,75	4,50

** USD por millón de tokens.*

Tabla 4: Precios de API y justificación del modelo elegido.

Análisis estadístico

La concordancia se codificó como variable ordinal (disparity = 1 … same = 4) y se analizó con tests de Kruskal-Wallis, con tamaño de efecto ε^2 para separar la significación estadística de la relevancia práctica en una muestra grande, y post-hoc de Dunn corregido por Holm. Una regresión logística ordinal con todas las variables (temática, idioma, periodo, confianza) comprobó la robustez de cada efecto. La calibración del evaluador se verificó con una correlación de Spearman; la homogeneidad de la composición temática, con Chi-cuadrado y V de Cramér; y la independencia idioma-periodo, con un test de Cochran-Mantel-Haenszel y un ANOVA con término de interacción. Para el alcance, un diagnóstico del porcentaje de ceros determinó que solo viewCount era analizable, transformado con log1p; la medida central es el ratio de captura (visualizaciones de Grok / visualizaciones del tweet original). Un análisis de contenido cualitativo de 80 casos de discordancia, con validación manual, complementó los resultados cuantitativos.

Resultados y discusión

Concordancia entre modelos

La distribución de veredictos (51% same, 31% mostly_same, 9% slight_diff, 9% disparity) se aleja drásticamente de la uniformidad que cabría esperar de dos evaluadores independientes (χ^2 = 1.145,9; p ≈ 0): Grok y Gemini coinciden en torno al 82% de los casos (Figura 2). Este resultado fundacional admite dos lecturas que el diseño cuantitativo no puede dirimir por sí solo. La optimista sostiene que ambos modelos tienden hacia una verdad verificable y que su acuerdo es señal de fiabilidad. Una lectura cautelosa advierte que podrían compartir sesgos de entrenamiento que les hacen coincidir incluso cuando se equivocan. El análisis cualitativo, más abajo, aporta evidencia para inclinar la balanza.

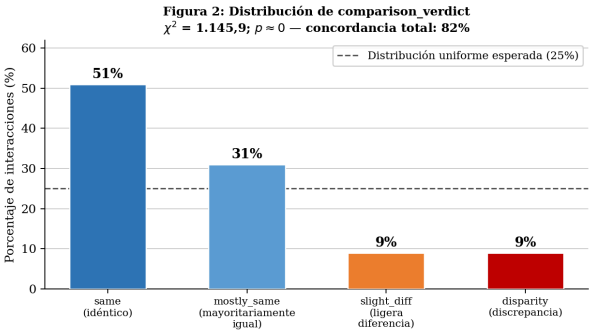


Figura 2: Distribución de comparison_verdict.

Factores del desacuerdo

Los tests univariantes detectan efectos significativos del periodo, la temática y el idioma, todos supervivientes a la corrección de Holm, además de una variación de la confianza del evaluador según la temática (Tabla 5). Los tamaños de efecto son, en todos los casos, pequeños. La confianza está bien calibrada: la correlación de Spearman entre confianza y concordancia es fuerte y positiva (ρ = 0,658; p ≈ 0), lo que valida el pipeline de anotación, ya que la confianza no es ruido sino una señal con contenido real.

Factor	H	p	ε^2	p-Holm
Periodo	14,56	0,00014	0,006	0,0004
Temática	33,14	0,0016	0,014	0,0027
Idioma	10,30	0,0013	0,004	0,0027
Confianza (temát.)	46,05	1,4e-5	0,020	0,00006

Tabla 5: Tests de Kruskal-Wallis sobre la concordancia.

La regresión ordinal con todas las variables controladas (Figura 3) ofrece el resultado más afinado: solo sobreviven como significativos el español (+0,31; p = 0,008), el periodo 2026 (+0,30; p < 0,001), la guerra (−0,67; p = 0,001) y la política (−0,38; p = 0,04). El desacuerdo entre modelos no es, por tanto, un fenómeno temático difuso, sino algo específico del contenido geopolíticamente sensible, donde la veracidad depende de fuentes en disputa y la frontera entre hecho e interpretación es porosa.

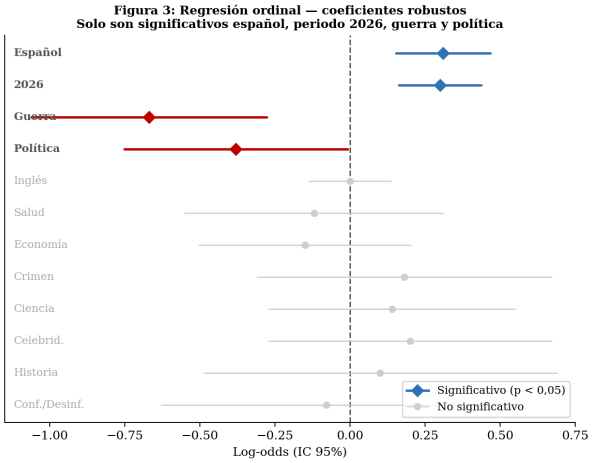


Figura 3: Regresión ordinal coeficientes robustos.

Dos comprobaciones cierran esta sección. El Chi-cuadrado de homogeneidad revela que la composición temática difiere notablemente entre periodos (V = 0,24) y de forma más leve entre idiomas (V = 0,13), por lo que el efecto temporal no puede leerse como una mejora de los modelos: parte de ese cambio refleja qué se fact-chequea en cada periodo. El Cochran-Mantel-Haenszel confirma que el efecto del idioma persiste dentro de cada periodo (OR = 0,697; IC 95% 0,50–0,97) y el ANOVA descarta interacción entre idioma y periodo (F = 0,12; p = 0,73): ambos efectos son aditivos e independientes.

Alcance de la corrección

El diagnóstico de engagement es contundente: bookmarks (100%), citas (99,9%), retweets (99,5%) y respuestas y likes (99,3%) presentan casi exclusivamente ceros; solo las visualizaciones tienen variabilidad real (mediana 52, máximo 111.351), por lo que el análisis se restringe a viewCount. El análisis descriptivo (Tabla 6) muestra que el español tiene algo más de audiencia que el inglés y que 2025 supera ligeramente a 2026, justo lo contrario que la concordancia, lo que confirma que engagement y concordancia son dimensiones independientes. El análisis por temática (Figura 4) lo refuerza: las temáticas más vistas (celebridades, deportes) no son las de mayor desacuerdo (guerra, política).

Grupo	Mediana*	Media*	n
2025	4,078	4,321	1.050
2026	3,829	4,183	1.303
Inglés	3,871	4,157	2.016
Español	4,317	4,770	337

** log(1 + visualizaciones).*

Tabla 6: Visualizaciones por periodo e idioma.

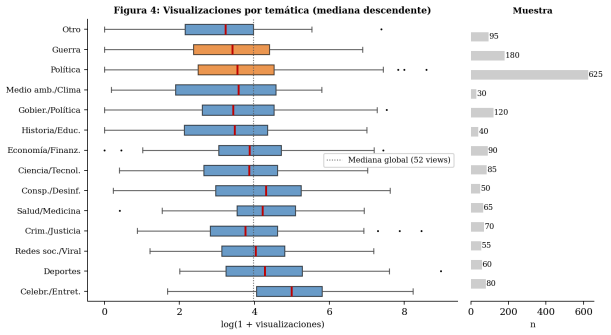


Figura 4: Visualizaciones (viewCount) por temática.

El hallazgo de mayor peso es el ratio de captura (Figura 5): su mediana es de 0,003, lo que significa que el fact-check típico de Grok alcanza apenas el 0,3% de la audiencia del tweet que corrige, y solo uno de cada diez supera al original en visualizaciones. Aunque sus veredictos sean consistentes, el alcance correctivo de Grok es marginal: la corrección existe, pero estructuralmente no llega a quienes vieron la afirmación inicial, resultado coherente con la asimetría entre el pico de difusión viral y el momento de llegada de las correcciones (Chuai et al., 2024; Vosoughi et al., 2018). Esto desplaza la pregunta relevante desde «¿acierta Grok?» hacia «¿llega la corrección de Grok a alguien?».

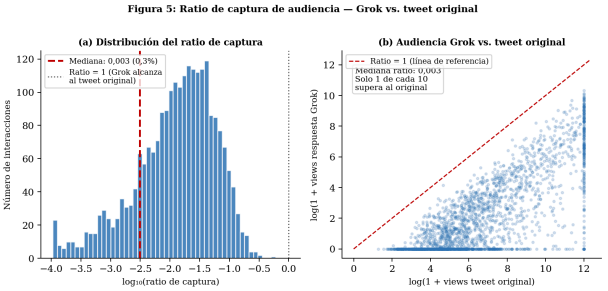


Figura 5: Ratio de captura — Grok vs. tweet original.

Análisis cualitativo

Sobre 80 casos de discordancia, Grok resulta más preciso en 37 (46,2%) frente a los 22 de Gemini (27,5%); en 13 no es posible determinar un veredicto, en 6 ambos modelos erran y en 4 ambos aciertan pero difieren en énfasis. La causa dominante del desacuerdo es temporal (35%): Gemini evalúa con un corte de conocimiento anterior al contexto del tweet, mientras que Grok dispone de información más reciente, lo que explica sus aciertos en eventos como el alto el fuego India-Pakistán, la captura de Maduro, la victoria del PSG en la Champions League o el fichaje de Mourinho por el Real Madrid. Le siguen la ambigüedad (27,5%), en la que ambos modelos responden a aspectos distintos y legítimos de una misma afirmación, y las fuentes de X (17,5%), donde Grok se apoya en contenido de la plataforma que puede ser sesgado, aunque su veredicto final suele ser igualmente acertado.

El patrón metodológicamente más relevante es la asimetría en las alucinaciones: Gemini alucina hechos verificables en el 10% de los casos frente al 2,5% de Grok, una proporción de cuatro a uno, negando en ocasiones eventos bien documentados como la victoria del PSG o una subida impositiva confirmada por fuentes oficiales. Este patrón sugiere que la concordancia observada refleja en buena medida una convergencia real hacia hechos verificables y no un artefacto de sesgos compartidos, e indica que el 82% global podría incluso subestimar el acuerdo real, ya que parte de las discordancias reflejan un déficit de información de Gemini y no una divergencia de criterio entre modelos comparables.

Tomados en conjunto, estos resultados configuran un triángulo de validación que mitiga la limitación de medir consistencia y no exactitud: la validación sobre LIAR, la convergencia entre Grok y Gemini que aquí documentamos, y la evidencia externa de Renault et al. (2026) de que las versiones API de Grok alcanzan un acuerdo con verificadores humanos estadísticamente equiparable al que existe entre los propios humanos. Si Grok se aproxima al juicio humano experto y converge con Gemini, la consistencia observada se ancla en una cadena de evidencia que conecta con el estándar humano.

Conclusiones

Este estudio aporta evidencia empírica de que dos modelos de lenguaje independientes convergen masivamente en sus veredictos de verificación, y de que su desacuerdo se concentra de forma robusta en el contenido bélico y político, precisamente la temática más demandada para verificación. Sin embargo, el alcance de la corrección de Grok es marginal: llega a una fracción ínfima de la audiencia del contenido que verifica.

La implicación principal es que mejorar la exactitud de estas herramientas resulta insuficiente si la corrección permanece invisible. El cuello de botella de la verificación automatizada en redes sociales no está hoy en la calidad del juicio, sino en su difusión, lo que sitúa el diseño de la plataforma y la visibilidad de las respuestas correctivas en el centro del problema. El estudio mide consistencia y no exactitud, y la muestra está desequilibrada hacia el inglés; el trabajo futuro debería incorporar un ground-truth multilingüe y un seguimiento longitudinal de las visualizaciones que permita distinguir la audiencia previa de la posterior a la intervención de Grok.

Bibliografía

Chuai, Y. et al. (2024). Did the roll-out of Community Notes reduce engagement with misinformation on X/Twitter?

Guo, Z., Schlichtkrull, M., & Vlachos, A. (2022). A Survey on Automated Fact-Checking. Transactions of the ACL.

Renault, T., Mosleh, M., & Rand, D. (2026). «@Grok is this true?» LLM-Powered Fact-Checking on Social Media.

Wang, W. Y. (2017). "Liar, Liar Pants on Fire": A New Benchmark Dataset for Fake News Detection. Proceedings of ACL 2017.

Boissonneault, D., & Hensen, R. (2024). Fake news detection with large language models on the LIAR dataset. ResearchGate. https://doi.org/10.13140/RG.2.2.36178.48323

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. Advances in Neural Information Processing Systems, 33, 9459–9474.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30.

Vosoughi, S., Roy, D., & Aral, S. (2018). The spread of true and false news online. Science, 359(6380), 1146–1151.

Wardle, C., & Derakhshan, H. (2018). Information disorder: Toward an interdisciplinary framework for research and policy making. Council of Europe.

Zheng, L., Chiang, W. L., Sheng, Y., et al. (2023). Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. Advances in Neural Information Processing Systems (NeurIPS 2023), 36.